Juan Esteban Salamanca

Andrés Felipe Fuentes

Laura Valentina Pinto

Entrega final de principios de M&S

En el presente documento se encuentra el análisis de la base de datos de sobre el estado financiero de varias empresas donde contamos con las siguientes variables:

Variables Numéricas:

- Edad: Representa la edad de la empresa en años.
- Ingresos: Los ingresos anuales en dólares.
- Gastos: Gastos anuales en dólares.
- Balance Deuda: El balance total de deuda de la empresa.
- Puntaje Crédito: Un puntaje crediticio que varía entre 300 y 850.
- Numero Productos: El número de productos financieros utilizados por la empresa.
- Historial Incidentes: Número de incidentes financieros previos que ha enfrentado la empresa.

Variables Categóricas:

- Región: La región geográfica donde opera la empresa (Norte, Sur, Este, Oeste).
- Tipo Empresa: Tipo de empresa según su estructura (Pequeña, Mediana, Grande).
- Sector: El sector económico en el que opera la empresa (Tecnología, Salud, Manufactura, Comercio, Servicios).

Variable Para Predecir (Objetivo):

- Estado Financiero: Representa si la empresa es financieramente saludable (1) o si está en riesgo financiero (0).

Por consiguiente, se hace el estudio pertinente para poder predecir si las empresas se encuentran en buen estado o no.

Exploración de los Datos:

```
df=pd.read_csv('C:/Users/soyju/Downloads/PRICNIPIOS M&S/ENTREGA FINAL/datos_clasificacion.txt',sep='\t')
df
```

Python

	Edad	Ingresos	Gastos	Balance_Deuda	Puntaje_Credito	Numero_Productos	Historial_Incidentes	Región	Tipo_Empresa	Sector	Estado_Financiero
0	56	128541	57380	2921	403	2	0	Este	Mediana	Manufactura	0
1	69	178696	55400	38740	700	8	4	Sur	Mediana	Tecnología	1
2	46	134634	41258	3387	545	5	0	Norte	Pequeña	Finanzas	0
3	32	148701	86006	11730	491	6	4	Este	Grande	Manufactura	0
4	60	77745	53957	15830	595	8	3	Oeste	Pequeña	Finanzas	1
...	...	...	...	...	...	...	...	...	...	...	...
11369	68	68865	37692	45541	368	2	0	Sur	Pequeña	Finanzas	1
11370	58	74457	44347	43970	744	3	3	Oeste	Pequeña	Salud	0
11371	27	110159	22189	3413	597	3	4	Sur	Mediana	Finanzas	0
11372	53	187889	12595	19027	773	2	4	Este	Grande	Finanzas	1
11373	37	113391	89148	8235	459	7	4	Oeste	Grande	Tecnología	0

11374 rows × 11 columns

Imagen 1: Datos obtenidos de la base de datos.

```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 11374 entries, 0 to 11373
Data columns (total 11 columns):
 #   Column                 Non-Null Count  Dtype
---  ------                 --------------  -----
 0   Edad                   11374 non-null  int64
 1   Ingresos               11374 non-null  int64
 2   Gastos                 11374 non-null  int64
 3   Balance_Deuda          11374 non-null  int64
 4   Puntaje_Credito        11374 non-null  int64
 5   Numero_Productos       11374 non-null  int64
 6   Historial_Incidentes   11374 non-null  int64
 7   Región                 11374 non-null  object
 8   Tipo_Empresa           11374 non-null  object
 9   Sector                 11374 non-null  object
 10  Estado_Financiero      11374 non-null  int64
dtypes: int64(8), object(3)
memory usage: 977.6+ KB
```

Imagen 2: Tipo de dato de cada variable.

```python
df_drop=df.dropna(axis=0)
df_drop
```

Python

	Edad	Ingresos	Gastos	Balance_Deuda	Puntaje_Credito	Numero_Productos	Historial_Incidentes	Región	Tipo_Empresa	Sector	Estado_Financiero
0	56	128541	57380	2921	403	2	0	Este	Mediana	Manufactura	0
1	69	178696	55400	38740	700	8	4	Sur	Mediana	Tecnología	1
2	46	134634	41258	3387	545	5	0	Norte	Pequeña	Finanzas	0
3	32	148701	86006	11730	491	6	4	Este	Grande	Manufactura	0
4	60	77745	53957	15830	595	8	3	Oeste	Pequeña	Finanzas	1
...	...	...	...	...	...	...	...	...	...	...	...
11369	68	68865	37692	45541	368	2	0	Sur	Pequeña	Finanzas	1
11370	58	74457	44347	43970	744	3	3	Oeste	Pequeña	Salud	0
11371	27	110159	22189	3413	597	3	4	Sur	Mediana	Finanzas	0
11372	53	187889	12595	19027	773	2	4	Este	Grande	Finanzas	1
11373	37	113391	89148	8235	459	7	4	Oeste	Grande	Tecnología	0

11374 rows × 11 columns

Imagen 3: Eliminación de datos.

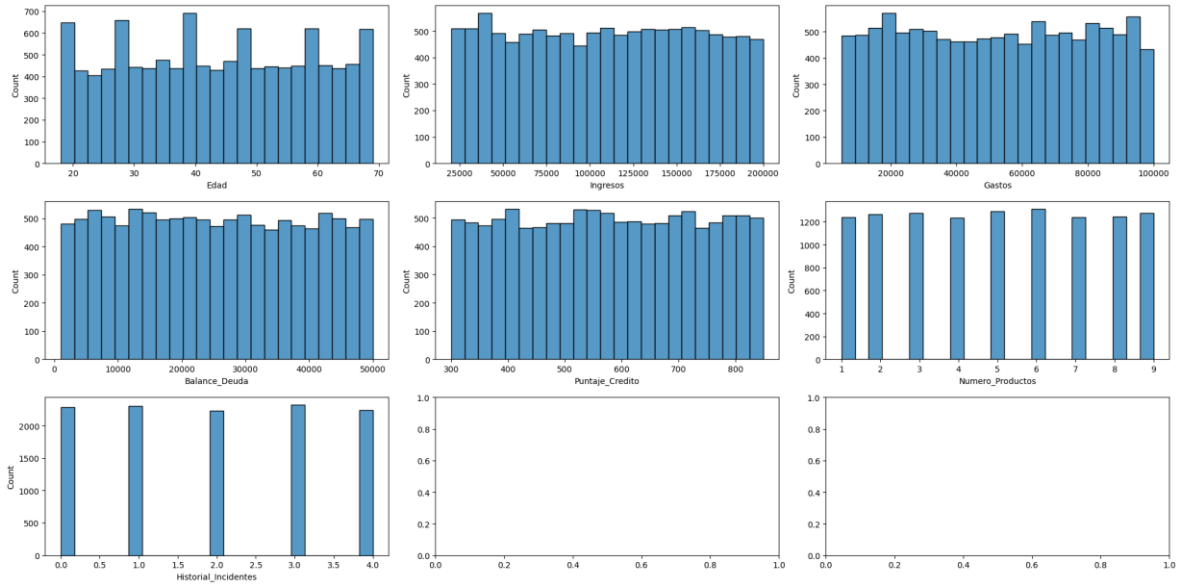

Imagen 4: Gráficas de conteo de datos de variables numéricas.

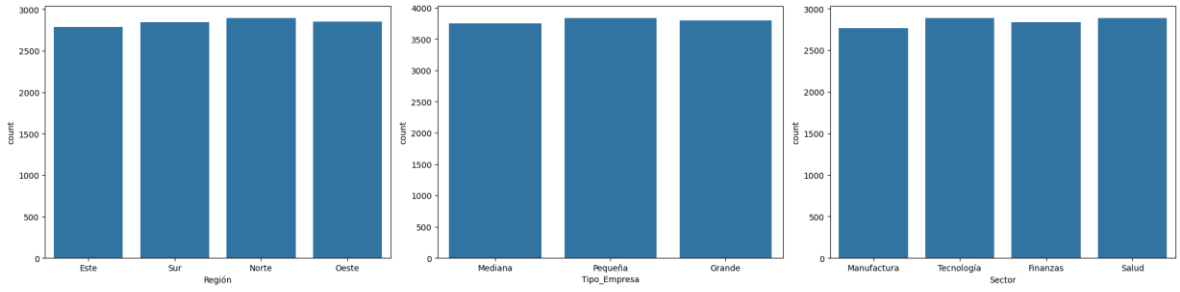

Imagen 5: Gráficas de conteo de datos de variables categóricas.

Preprocesamiento de los Datos:

Estandarización:

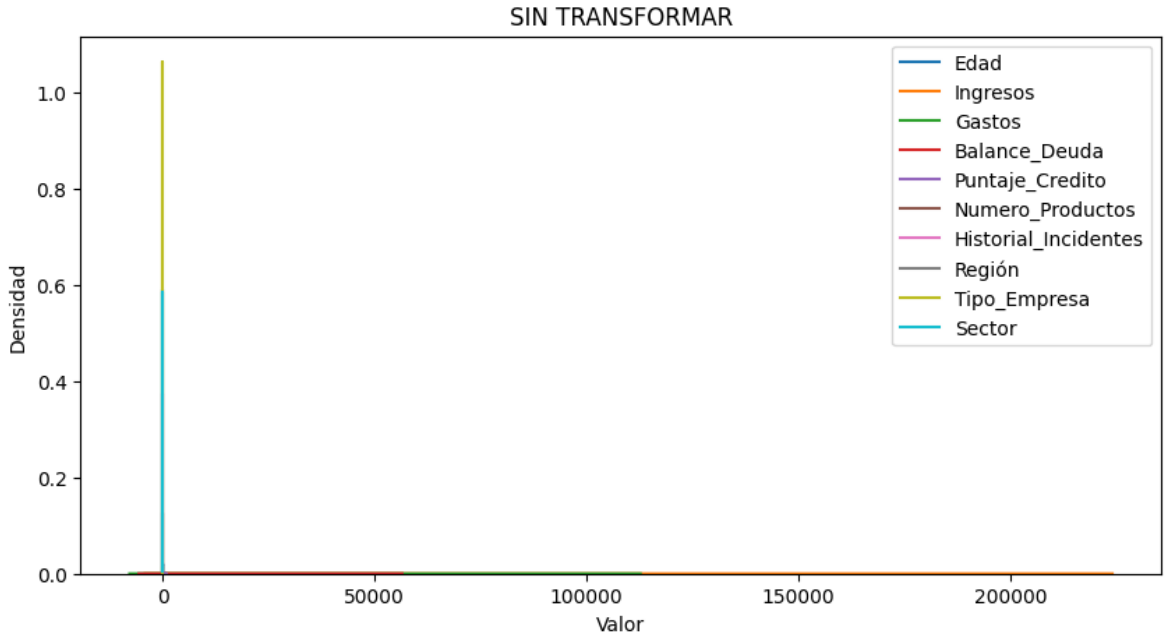

Imagen 7: Gráfica de datos sin transformar.

Codificación de Variables Categóricas:

Al aplicar el comando dummy, las variables categóticas (Tipo_Empresa, Región y Sector) toman números específicos para su debido uso, presentados en la siguiente imagen:

```
columnas_dummy=df.columns[df.dtypes==object]
columnas_dummy
```

```
Index(['Región', 'Tipo_Empresa', 'Sector'], dtype='object')
```

```
from sklearn.preprocessing import LabelEncoder
lb = LabelEncoder()
df['Región']=lb.fit_transform(df['Región'].values)
df['Tipo_Empresa']=lb.fit_transform(df['Tipo_Empresa'].values)
df['Sector']=lb.fit_transform(df['Sector'].values)
df.head(5)
```

	Edad	Ingresos	Gastos	Balance_Deuda	Puntaje_Credito	Numero_Productos	Historial_Incidentes	Región	Tipo_Empresa	Sector	Estado_Financiero
0	56.0	128541.0	57380.0	2921.0	403.0	2.0	0.0	0	1	1	0.0
1	69.0	178696.0	55400.0	38740.0	700.0	8.0	4.0	3	1	3	1.0
2	46.0	134634.0	41258.0	3387.0	545.0	5.0	0.0	1	2	0	0.0
3	32.0	148701.0	86006.0	11730.0	491.0	6.0	4.0	0	0	1	0.0
4	60.0	77745.0	53957.0	15830.0	595.0	8.0	3.0	2	2	0	1.0

Imagen 8: Aplicación del comando dummy a variables categóricas.

Región:

- Este: 0
- Norte: 1
- Oste: 2
- Sur: 3

Tipo_Empresa:

- Grande:0
- Mediana:1
- Pequeña: 2

Sector:

- Finanzas:0
- Manufactura: 1
- Salud: 2
- Tecnología:3

Reducción de Dimensionalidad:

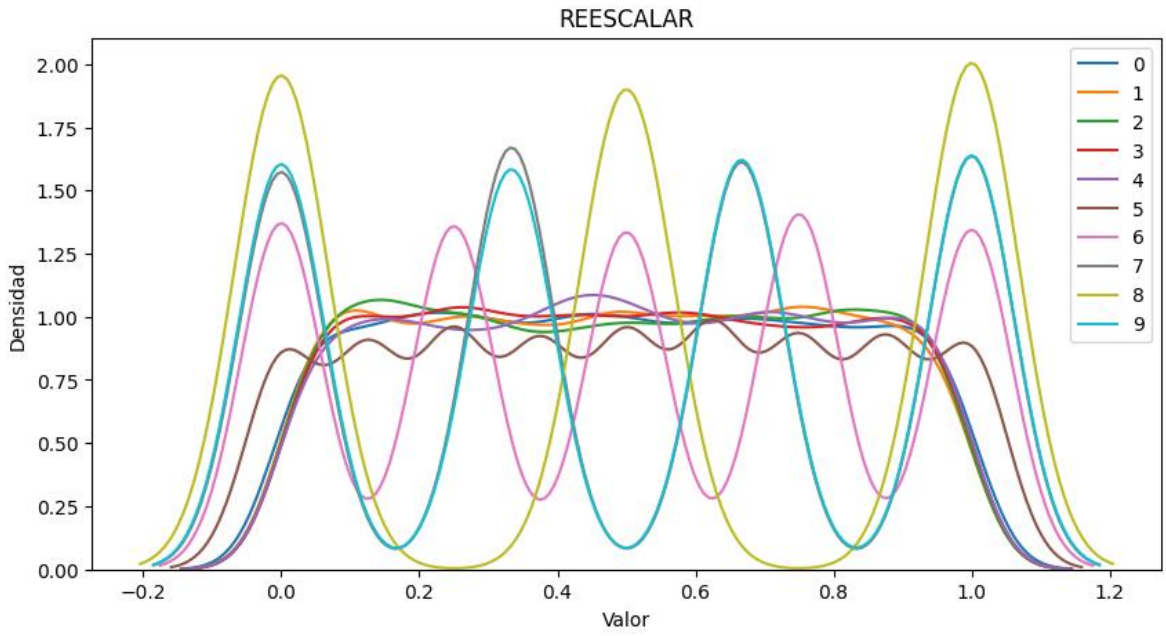

Imagen 9: Gráfica de reescalar.

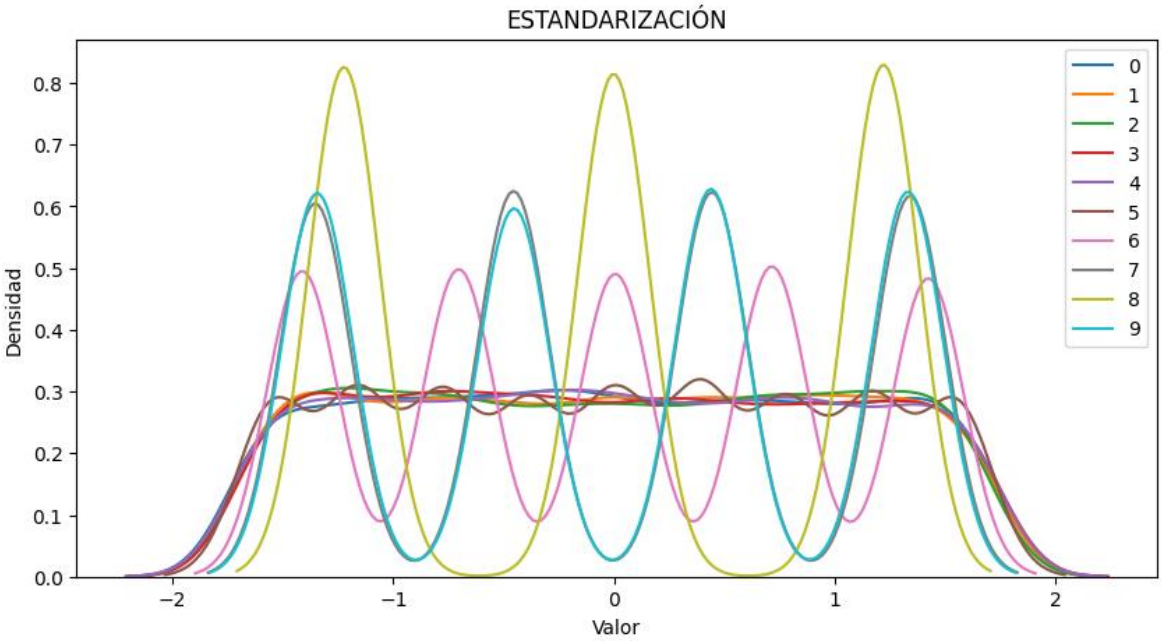

Imagen 10: Gráfica de estandarización.

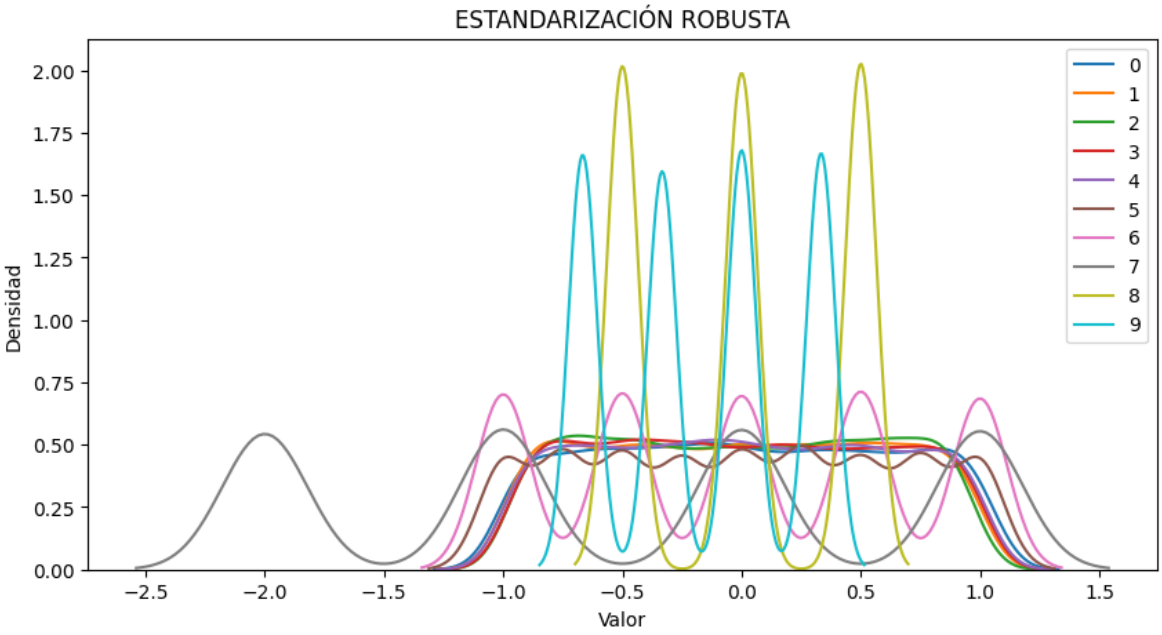

Gráfica 11: Gráfica de estandarización robusta.

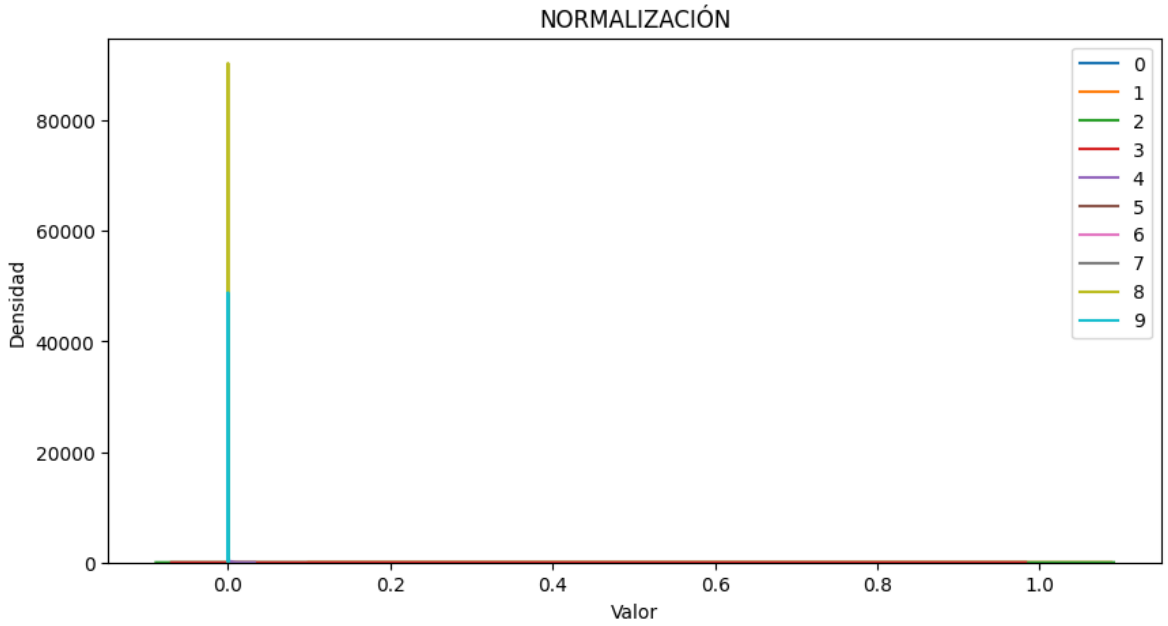

Imagen 12: Gráfica de normalización.

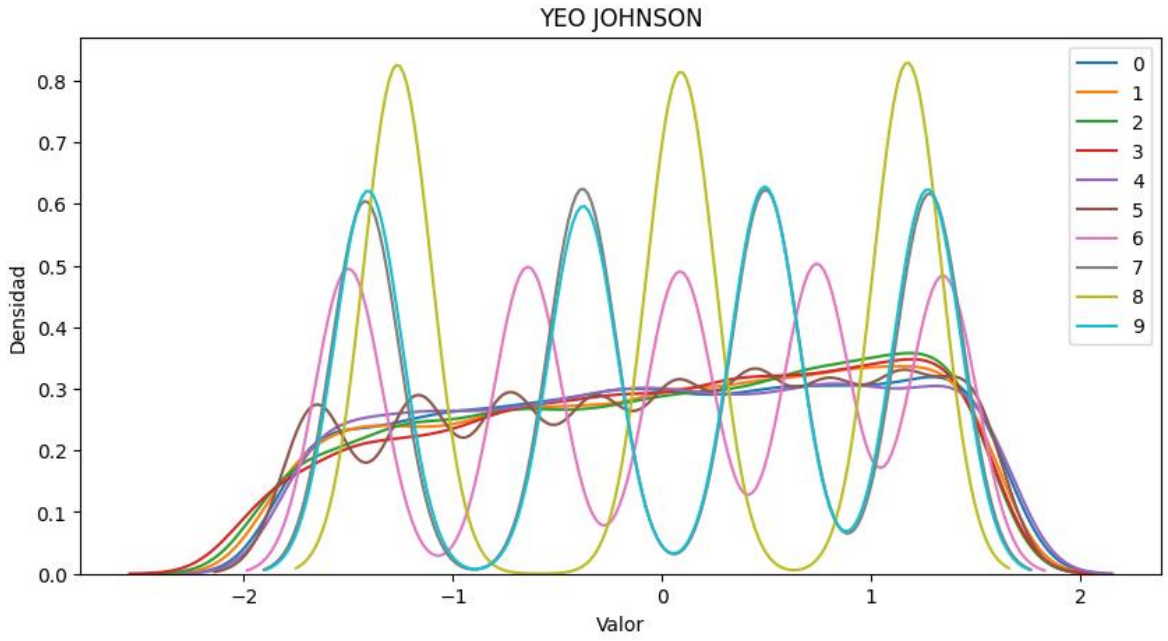

Imagen 13: Gráfica de Yeo Johnson.

Después de tener los datos con el modelo de Yeo Johnson, se procede con los modelos de clasificación:

Construcción del Modelo de Clasificación:

Imagen 14: Modelo SVC.

Imagen 15: Modelo Decisión Tree.

Imagen 16: Modelo Random Forest.

Comparando los modelos, podemos observar que el mejor modelo de los 3 escogidos es Random Forest debido a que nuestro conjunto de datos es muy amplio y este modelo arrojo un rendimiento bastante alto de 0.5248 al combinar múltiples árboles de decisión ayuda a mejorar la precisión y reducir el sobreajuste que se hace. Además este modelo permite poder modelar el comportamiento de los datos de un mejor forma en comparación con SVC y Tree.

```
  Resultados para Decision Tree:
              precision    recall  f1-score   support

         0.0       0.50      0.49      0.49      1142
         1.0       0.50      0.51      0.50      1133

    accuracy                           0.50      2275
   macro avg       0.50      0.50      0.50      2275
weighted avg       0.50      0.50      0.50      2275

  Matriz de Confusión:
  [[556 586]
   [558 575]]
```

Imagen 17: Métricas del modelo Decision Tree.

```
Resultados para Random Forest:
              precision    recall  f1-score   support

         0.0       0.50      0.49      0.49      1142
         1.0       0.50      0.51      0.50      1133

    accuracy                           0.50      2275
   macro avg       0.50      0.50      0.50      2275
weighted avg       0.50      0.50      0.50      2275

Matriz de Confusión:
[[557 585]
 [558 575]]
```

Imagen 18: Métricas del modelo Random Forest.

```
Resultados para SVM:
              precision    recall  f1-score   support

         0.0       0.50      0.49      0.49      1142
         1.0       0.49      0.50      0.50      1133

    accuracy                           0.49      2275
   macro avg       0.49      0.49      0.49      2275
weighted avg       0.49      0.49      0.49      2275

Matriz de Confusión:
[[554 588]
 [565 568]]
```

Imagen 19: Métricas del modelo SVC.

Optimización del Modelo:

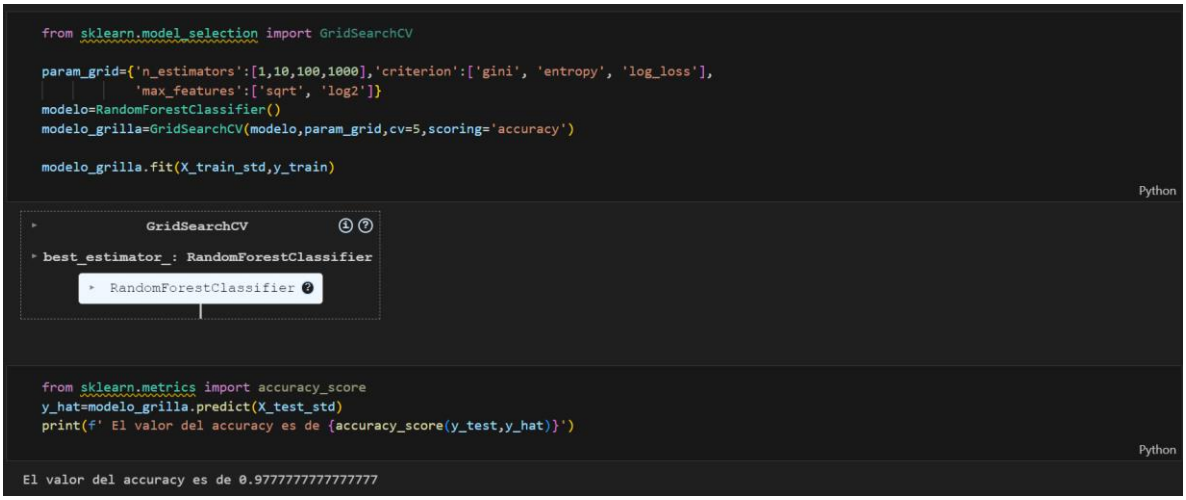

Imagen 20: Modelo grilla

Al hacer la optimización del modelo Random Forest se tiene un aumento a 0,97 lo que es un comportamiento mucho al valor obtenido por el no optimizado de 0,52, haciendo este modelo optimizado algo que se aproxime más a la realidad del comportamiento de los datos.

```
y_hat_prueba=modelo_grilla.predict(X_test_std)
precision= precision_score(y_test,y_hat_prueba,average='weighted')
recall=recall_score(y_test,y_hat_prueba,average='weighted')
f1=f1_score(y_test,y_hat_prueba,average='weighted')
accuracy = accuracy_score(y_test, y_hat_prueba)
```

+ Code + Markdown

```
print("Precisión: ", round(precision*100,2))
print("Exhaustividad: ", round(recall*100,2))
print("Puntuación F1: ", round(f1*100,2))
print("Exactitud: ", round(accuracy*100,2))
```

```
Precisión:  97.89
Exhaustividad:  97.78
Puntuación F1:  97.76
Exactitud:  97.78
```

Imagen 21: Modelo grilla con variable test.

```
y_hat_entrenamiento=modelo_grilla.predict(X_train_std)
precision= precision_score(y_train,y_hat_entrenamiento,average='weighted')
recall=recall_score(y_train,y_hat_entrenamiento,average='weighted')
f1=f1_score(y_train,y_hat_entrenamiento,average='weighted')
accuracy = accuracy_score(y_train, y_hat_entrenamiento)
```

```
print("Precisión: ", round(precision*100,2))
print("Exhaustividad: ", round(recall*100,2))
print("Puntuación F1: ", round(f1*100,2))
print("Exactitud: ", round(accuracy*100,2))
```

```
Precisión:  96.3
Exhaustividad:  96.19
Puntuación F1:  96.2
Exactitud:  96.19
```

Imagen 22: Modelo grilla con variable real.

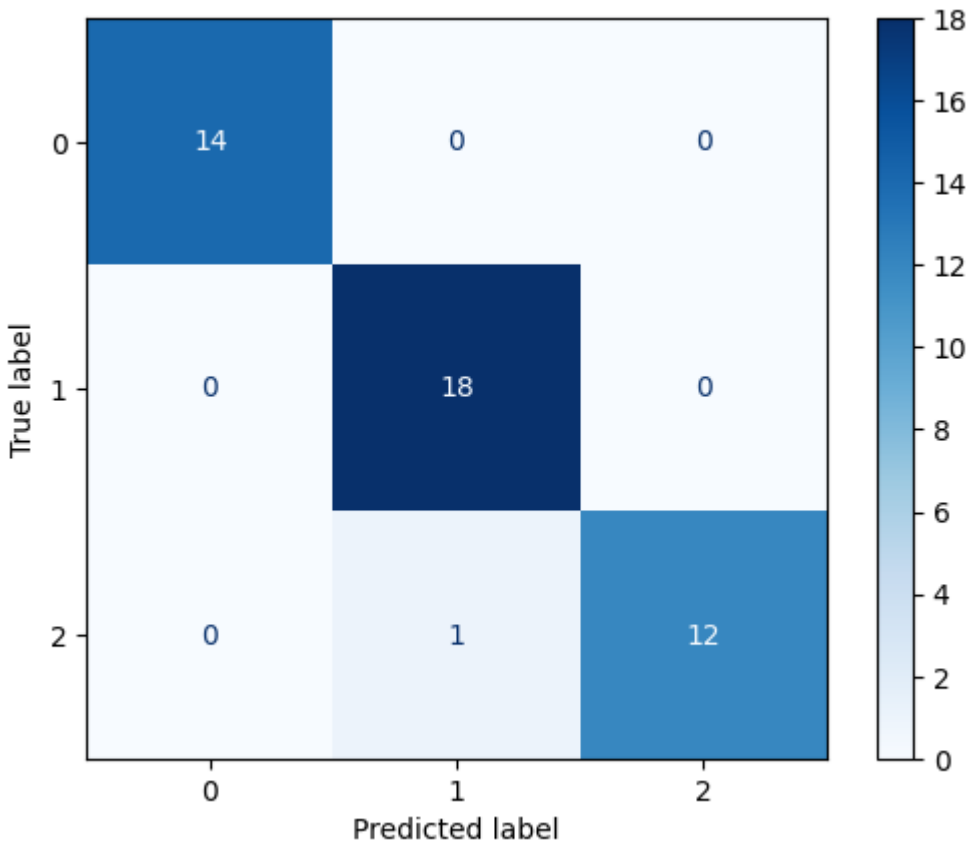

Imagen 23: Matriz de confusión de datos.

Basándonos en esta matriz, podemos decir que el modelo tiene un buen desempeño en las clases 0 y 1, debido a que la mayoría de los datos de fueron clasificados correctamente, por ejemplo, el modelo clasificó correctamente 14 datos como de la clase 0, 18 de la clase 1 y 12 de la clase 2. Sin embargo, hay cierta confusión en la clase 2, ya que un dato fue clasificado incorrectamente como de la clase 1.